

Relatório Final

ELT Analítico — Corridas de Táxi de Nova York

Yellow Taxi Trip Records — Janeiro/2024

Processo Seletivo da Liga Acadêmica de Engenharia de Dados (LED) — CIn/UFPE

Grupo 11

Eduarda Torres, Esdras Albino, Larissa Almeida, Mirella Fontinelle, Pedro Alves

28 de julho de 2026
Recife, Pernambuco

1. Visão geral do desafio

O desafio, proposto pela LED (Liga Acadêmica de Engenharia de Dados, CIn/UFPE pediu a construção de um processo ELT completo sobre os registros públicos de corridas de táxi de Nova York (Yellow Taxi), recorte de janeiro de 2024.

Princípio central do desafio: os dados brutos são carregados no ambiente analítico antes de qualquer transformação, e toda a lógica de limpeza, tratamento e modelagem acontece dentro do banco, em SQL — sem edição manual do arquivo de origem, sem uso de planilhas, notebooks ou ferramentas de BI para transformar dados.

1.1 Escopo técnico exigido

- Camada bruta (raw): cópia fiel da fonte, preservada para auditoria.
- Perfilamento: investigação sistemática de tipos, nulidade, domínio, cardinalidade e valores improváveis, com consultas versionadas.
- Camada de tratamento (staging): padronização e limpeza, com toda regra justificada e rastreável.
- Modelo dimensional (star schema): pelo menos uma tabela fato e três dimensões, com grão declarado.
- Camada de consumo analítico: consultas que respondem perguntas de negócio, sobre o modelo — nunca sobre o arquivo bruto.

1.2 Ambiente e ferramentas

DuckDB (linha de comando, via container Docker Compose com versão pinada), GitHub para versionamento, e SQL como única linguagem de transformação permitida.

1.3 Grão declarado da tabela fato

Declaração de grão

Uma linha de fato_corrida representa uma corrida individual de táxi — um evento de taxímetro completo, do acionamento (pickup_datetime) ao desligamento (dropoff_datetime), que passou pelas regras de limpeza da camada de staging.

O grão não desce (a fonte não fornece segmentos de trajeto) e não sobe (agregar por zona/hora na própria fato inviabilizaria as análises de tempo, geografia, financeiro e operação exigidas pelo desafio).

2. Fonte de dados e dicionário

Duas fontes compõem a camada bruta: os registros de corrida (raw_trips, formato Parquet) e a tabela de referência de zonas (raw_zone_lookup, CSV). Ambas recebem duas colunas técnicas adicionais na carga — _loaded_at e _source_file — puramente aditivas, para auditoria e rastreabilidade, sem alterar nenhuma coluna original.

2.1 raw_trips — campos principais

Campo	Descrição	Observação
VendorID	Código do provedor TPEP que registrou a corrida (não é motorista nem veículo).	Em jan/2024 só ocorrem os códigos 1, 2 e 6 — o código 7 (Helix, dicionário 2025) está ausente.
tpep_pickup/dropoff_datetime	Acionamento e desligamento do taxímetro.	0% nulo; contém valores fora do escopo temporal (ver §3 e §6).

Campo	Descrição	Observação
passenger_count	Nº de passageiros, preenchido pelo motorista.	4,73% nulo — parte do grupo de nulos conjunto (§3.2).
trip_distance	Distância em milhas, reportada pelo taxímetro.	Contém outliers extremos, tratados via flag (§4, regra 4).
RatecodeID	Código de tarifa final (1–6, 99 = unknown).	Domínio bate com o dicionário oficial.
PULocationID / DOLocationID	Zona de embarque / desembarque.	Chave para raw_zone_lookup.LocationID.
payment_type	Forma de pagamento (0–6).	Códigos 5 e 6 do dicionário não ocorrem em jan/2024.
fare_amount, extra, mta_tax, tip_amount, tolls_amount, improvement_surcharge, congestion_surcharge, Airport_fee, total_amount	Componentes monetários da cobrança.	Contém valores negativos (estorno) e um teto de sistema em 5000/2500 (§4).

2.2 raw_zone_lookup

Campo	Descrição	Observação
LocationID	Identificador único da zona.	Chave natural — 1 a 265.
Borough	Distrito de NY.	'N/A' e 'Unknown' são texto literal, não NULL.
Zone	Nome descritivo da zona.	262 nomes distintos para 265 IDs — não é 1:1 (ex.: Governor's/Ellis/Liberty Island cobrem 103–105).
service_zone	Categoria de área de serviço.	Não serve como critério de aeroporto (§4, regra 8).

Detalhamento completo, com tipos e domínios integrais, em docs/dicionario_dados.md.

3. Perfilamento dos dados

Perfilamento das 19 colunas de negócio de raw_trips (2.964.624 linhas) e das 4 colunas de raw_zone_lookup (265 linhas). Confirmou-se, entre outros pontos, que a base já está no grão de corrida individual: comparando o total de linhas com o total de linhas distintas considerando todas as 19 colunas de negócio, o resultado é $2.964.624 = 2.964.624$ — zero duplicatas.

3.1 Principais achados

- Grupo de nulos conjunto: 5 colunas (passenger_count, RatecodeID, store_and_fwd_flag, congestion_surcharge, Airport_fee) são nulas exatamente nas mesmas 140.162 linhas, todas com payment_type = 0 (Flex Fare trip) — ausência estrutural, não falha de captura.
- Estornos: valores monetários negativos concentrados em payment_type 3 (No charge) e 4 (Dispute) — padrão consistente com reversão de cobrança.
- Distância improvável: 819 corridas (trip_distance > 50mi OU razão distância/tarifa > 5), limiar validado por quantil (p99,9 = 29,5mi).
- Gorjetas atípicas: 4.213 linhas (tip > 50 OU tip > fare_amount).

- Teto de sistema: valores máximos concentrados em 5000,0 e 2500,0 exatos em fare_amount/total_amount.
- total_amount não é derivável dos demais componentes: a soma só fecha em 74,3% das linhas — divergência residual explicada por congestion_surcharge.
- 'N/A' e 'Unknown' em raw_zone_lookup existem como texto literal, não como NULL — exigem normalização explícita por CASE, não por filtro de nulidade.

3.2 Datas fora do escopo temporal

Encontradas 18 corridas com pickup fora de janeiro/2024 e 56 com dropoff antes do pickup (fisicamente impossível) — tratamento detalhado em §4 e auditado em §6.

Perfilamento completo (tabela-síntese, consultas versionadas e detalhamento por variável) em docs/perfilamento_notas.md; a hipótese de grão derivada dele está em docs/hipotese_grao.md.

4. Regras de limpeza e tratamento (staging)

Toda regra segue a classificação exigida pelo desafio:

Ausente (campo estruturalmente não preenchido), Desconhecido (valor existe mas não identificável), Incomum (raro, mas explicável pelo negócio) e Inválido (viola regra lógica básica ou está fora do escopo). Para inválido e incomum, a regra padrão é nunca excluir silenciosamente: a linha é mantida com flag booleana, ou — só quando não há leitura de negócio possível — é excluída e registrada como rejected record.

#	Achado	Ação
1	Datas inválidas (74 linhas: 18 fora de jan/2024 + 56 dropoff antes do pickup)	Excluir da fato + registrar rejected record
2	Valores monetários negativos (estorno)	Manter + flag is_estorno
3	payment_type 5/6 ausentes em jan/2024	Documentado; dimensão prevê os códigos
4	Distância improvável (819 corridas)	Manter + flag is_distance_outlier
4b	Distância zero anômala em RatecodeID = 1	Manter, sem flag dedicada (correlação duração×tarifa continua fraca)
5	Detector por velocidade implícita (> 50mph)	Manter + flag is_speed_outlier
6	Nulos ligados a payment_type = 0 (140.162 linhas)	NULL mantido nas medidas; membro dimensional "Não se aplica" nos atributos categóricos
7	Gorjetas atípicas (4.213 linhas)	Manter + flag is_tip_outlier
8	Critério de "corrida de aeroporto"	is_aeroporto = COALESCE(Airport_fee, 0) > 0
9	"N/A"/"Unknown" como texto literal em zone_lookup	Normalizar explicitamente em dim_zona
10	Reconciliação de total_amount	Manter valor da fonte, não recalcular
11	Teto de sistema (5000/2500 exatos)	Manter + flag is_fare_outlier

Justificativa completa, item a item, com a evidência quantitativa que sustenta cada limiar, em docs/regras_limpeza.md.

5. Modelagem dimensional — star schema

5.1 Estrutura

O modelo tem uma tabela fato (fato_corrida) e quatro dimensões: dim_data e dim_hora (role-playing — cada uma referenciada duas vezes, para embarque e desembarque), dim_zona (também

role-playing, PU/DO) e dim_pagamento. Uma junk dimension, dim_atributos_corrida, consolida três códigos operacionais de baixa cardinalidade (VendorID, RatecodeID, store_and_fwd_flag) que não justificam dimensão própria — 25 combinações observadas.

5.2 Chaves — naturais e substitutas

Tabela	Chave natural	Chave substituta	Justificativa
fato_corrida	Combinação das 19 colunas de negócio (comprovadamente única)	id_corrida_sk (hash determinístico)	Chave natural impraticável como PK; hash garante idempotência entre execuções
dim_data	A própria data	id_data_sk (AAAAMMDD)	Chave inteligente, legível e ordenável
dim_hora	Hora do dia (0–23)	id_hora_sk	Domínio fechado e estável
dim_zona	location_id	id_zona_sk	Chave da fonte é íntegra e estável; nome da zona não é 1:1
dim_pagamento	payment_type	id_pagamento_sk	Domínio fechado de 7 códigos do dicionário TLC
dim_atributos_corrida	Combinação dos 3 códigos	id_atributos_sk	Junk dimension — chave inteiramente artificial

5.3 Como o modelo trata ausência

Nenhuma FK da fato é nula, e nenhuma coluna de atributo das dimensões é nula — regra adotada porque NULL não responde a comparação (WHERE ratecode_id <> 99 descartaria silenciosamente as linhas de Flex Fare junto com as de código 99, sem erro aparente).

- Valor reservado -1 (numérico) / 'N/A' (texto): ausência estrutural (grupo Flex Fare, payment_type = 0).
- Código 99 da própria fonte: usado como "Desconhecido" — não precisa de valor reservado próprio.
- Em dim_atributos_corrida (junk), o valor reservado vai na coluna de atributo, não na chave — um -1 universal perderia a distinção entre os 3 vendedores; cada combinação observada mantém linha própria.
- Nas medidas da fato (passenger_count, congestion_surcharge, Airport_fee), o NULL é preservado — um 0 no lugar seria lido como "não pagou" e distorceria SUM/AVG.

5.4 Atributos redundantes materializados

Seis flags booleanas (is_estorno, is_speed_outlier, is_tip_outlier, is_distance_outlier, is_fare_outlier, is_aeroporto) são funções determinísticas de medidas já presentes na fato — tecnicamente recalculáveis a cada consulta. São materializadas mesmo assim porque cada uma corresponde a um limiar decidido com evidência quantificada; a flag é o contrato da regra de qualidade, evitando que a definição divirja entre analistas.

trip_duration_minutes é a única medida derivada materializada, por ser aditiva (soma corretamente em qualquer recorte). Razões como velocidade, percentual de gorjeta e preço por milha ficam fora da fato — não são aditivas, e uma média de razões não equivale à razão das somas.

6. Estudo de caso — auditoria e correção de uma regra de limpeza

Uma evidência do processo de auditoria e reconciliação do projeto foi a tentativa de responder à pergunta "como o pipeline prova que produziu dados confiáveis?").

6.1 O que foi encontrado

Na revisão cruzada da documentação, dois grupos de documentos declararam números diferentes para a regra 1 (datas inválidas): docs/perfilamento_notas.md e docs/hipotese_grao.md registravam 18

corridas com pickup fora de janeiro/2024 (+ 56 dropoff antes do pickup = 74 no total), enquanto docs/regras_limpeza.md e docs/decisoes.md, numa correção anterior, registravam 15 (+ 56 = 71).

6.2 Como foi verificado

A verificação foi feita direto sobre raw_trips, sem depender da staging — evita validar a lógica de staging contra ela mesma:

```
SELECT COUNT(*) FROM raw_trips WHERE tpep_pickup_datetime < '2024-01-01' OR
tpep_pickup_datetime >= '2025-01-01'; -- filtro por ANO → 15

SELECT COUNT(*) FROM raw_trips WHERE tpep_pickup_datetime < '2024-01-01' OR
tpep_pickup_datetime >= '2024-02-01'; -- filtro por MÊS (jan/2024) → 18
```

Em seguida, consultou-se o resultado já materializado do staging:

```
SELECT COUNT(*) FROM rejected_trips WHERE rejection_reason = 'REJEITADO_FORA_DO_PERIODO'; --
15
```

6.3 Causa raiz

O código de stg_yellow_trips.sql estava aplicando o filtro por ano (>= '2025-01-01') em vez do filtro por mês/jan-2024 (>= '2024-02-01') que a própria descrição da regra em docs/decisoes.md já prometia ("se pickup_datetime cai fora de jan/2024"). O erro era uma divergência entre a regra escrita e a condição implementada no SQL, apesar de ter parecido ser um equívoco uivo de documentação por um momento. Três corridas com pickup em outro mês de 2024 estavam sendo aprovadas indevidamente.

6.4 Correção e nova validação

- Condição corrigida em stg_yellow_trips.sql: limite superior de >= '2025-01-01' para >= '2024-02-01'.
- Pipeline reexecutado do zero; rejected_trips passou a registrar 18 corridas pelo motivo REJEITADO_FORA_DO_PERIODO (total de rejeitados: 74).
- fato_corrida recalculada: 2.964.550 linhas (antes: 2.964.553 — a diferença de 3 corresponde exatamente às 3 corridas agora corretamente excluídas).
- Reconciliação reconferida: SUM(total_amount) de raw_trips menos fato_corrida é 2.318,78 — bate exatamente com a soma de rejected_trips.total_amount, confirmando que nenhum valor foi perdido nem duplicado.
- Números atualizados em regras_limpeza.md e decisoes.md; correção registrada como entrada própria em decisoes.md, no mesmo formato das demais (antes/depois + justificativa).

Conclusão

Esse pequeno acontecimento é o exemplo prático de reconciliation e idempotent SQL pipeline. A regra estava documentada de um jeito e implementada de outro, a discrepância só apareceu porque os documentos foram cruzados deliberadamente, a correção foi feita na fonte (SQL) e o pipeline foi reexecutado do zero para confirmar. Nenhum dado foi editado fora do fluxo ELT.

7. Papel de cada integrante

Fase	Responsáveis	Entregável
1 — Extração e configuração de ambiente	Esdras Albino, Pedro Alves	Docker Compose, carga da camada raw
2 — Perfilamento	Mirella Fontinelle, Eduarda Torres, Larissa Almeida	docs/perfilamento_notas.md, docs/hipotese_grao.md

Fase	Responsáveis	Entregável
3 — Staging / tratamento	Esdras Albino	staging/*.sql, docs/regras_limpeza.md, quarentena (rejected_trips)
4 — Modelagem dimensional	Eduarda Torres	model/dims/*.sql, model/facts/*.sql, docs/modelagem_dimensional.m d
5 — Consumo analítico e fechamento	Esdras Albino, Eduarda Torres (principal)	Consultas de negócio, reconciliação final
Documentação (transversal)	Mirella Fontinelle	Consolidação de toda a documentação, revisão de consistência entre docs, auditoria numérica (§6)

Papel transversal: a documentação acompanhou todas as fases, e não uma etapa isolada — inclui a revisão de consistência entre os documentos técnicos que revelou a divergência descrita em §6.

8. Uso de LLM

O edital permite LLM como apoio à aprendizagem e proíbe como executora do projeto. Ferramentas de IA (Claude) foram usadas ao longo do desafio exclusivamente como apoio ao aprendizado, nunca como executoras do projeto — conforme a regra central da seção 05.

8.1 Mirella Fontinelle — perfilamento e documentação

- Entendimento dos fundamentos do perfilamento e do uso de Docker.
- Revisão de consistência entre os documentos técnicos já escritos pela equipe
- Apoio na consolidação desta documentação final.

8.2 Larissa Almeida — perfilamento

- Explicação de conceitos técnicos (ELT vs. ETL, modelagem dimensional, star schema, junk dimension, role-playing dimension, idempotência).
- Ajuda para interpretar erros de terminal, Git e SQL durante a configuração do ambiente e a execução das consultas.
- Apoio para estruturar e formatar as anotações de perfilamento.
- Revisão de clareza em comentários de code review.

8.3 Esdras Albino — staging, consumo analítico

- Planejamento do projeto e de tarefas.
- Apoio em documentação e code review.
- Aprimoramento de insights próprios.

8.4 Pedro Alves — extração e configuração de ambiente

- Entendimento de como o DuckDB funciona e de funções de SQL.
- Code review e explicação de erros que ocorriam ao rodar a parte de staging.

8.5 Eduarda Torres

- Entendimento do projeto e do desenvolvimento de tasks avançadas.
- Apoio em documentação e code review durante todo o modelamento.
- Amadurecimento de decisões e análise de erros minuciosos.

9. Referências

- NYC TLC — Yellow Taxi Trip Records e Data Dictionary (versão 18/03/2025).
- TLC Taxi Zone Lookup Table.
- Kimball, Ralph & Ross, Margy. The Data Warehouse Toolkit. 3rd ed. Wiley, 2013 — declaração de grão, surrogate keys, dimensões degeneradas, junk dimensions, role-playing dimensions, aditividade.

9.1 Documentos de origem (repositório)

- docs/dicionario_dados.md
- docs/perfilamento_notas.md
- docs/hipotese_grao.md
- docs/regras_limpeza.md
- docs/modelagem_dimensional.md
- docs/decisoese.md